

paez_jean_EA4

March 22, 2025

1 EA4: MNIST desde cero

1.0.1 Apellido_Nombre_EA4.ipynb

1.1 Objetivo

Implementar dos clasificadores para el conjunto de datos MNIST: 1. Una implementación desde cero sin usar bibliotecas de alto nivel 2. Una implementación usando scikit-learn

```
[1]: # Importamos solo las bibliotecas básicas necesarias
import numpy as np
import matplotlib.pyplot as plt
from sklearn.datasets import fetch_openml
from sklearn.model_selection import train_test_split
```

1.2 1. Carga y Preparación de Datos

Primero, cargaremos el conjunto de datos MNIST y lo prepararemos para su uso.

```
[2]: # Cargamos MNIST
print("Cargando dataset MNIST...")
mnist = fetch_openml('mnist_784', version=1)
X, y = mnist.data.astype('float32'), mnist.target.astype('int32')

# Normalizamos los datos al rango [0,1]
X = X / 255.0

# Dividimos en conjuntos de entrenamiento y prueba
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
    random_state=42)

print("Forma de los datos de entrenamiento:", X_train.shape)
print("Forma de los datos de prueba:", X_test.shape)
```

Cargando dataset MNIST..

Forma de los datos de entrenamiento: (56000, 784)

Forma de los datos de prueba: (14000, 784)

1.3 2. Implementación desde Cero

Implementaremos una red neuronal simple con: - Capa de entrada: 784 neuronas (28x28 píxeles) - Capa oculta: 128 neuronas - Capa de salida: 10 neuronas (dígitos 0-9)

```
[3]: class NeuralNetworkFromScratch:
    def __init__(self, input_size, hidden_size, output_size):
        # Inicialización de pesos y sesgos
        self.W1 = np.random.randn(input_size, hidden_size) / np.sqrt(input_size)
        self.b1 = np.zeros((1, hidden_size))
        self.W2 = np.random.randn(hidden_size, output_size) / np.
        sqrt(hidden_size)
        self.b2 = np.zeros((1, output_size))

    def relu(self, X):
        """Función de activación ReLU"""
        return np.maximum(0, X)

    def relu_derivative(self, X):
        """Derivada de ReLU"""
        return X > 0

    def softmax(self, X):
        """Función softmax para la capa de salida"""
        exp_X = np.exp(X - np.max(X, axis=1, keepdims=True))
        return exp_X / np.sum(exp_X, axis=1, keepdims=True)

    def forward(self, X):
        """Propagación hacia adelante"""
        self.Z1 = np.dot(X, self.W1) + self.b1
        self.A1 = self.relu(self.Z1)
        self.Z2 = np.dot(self.A1, self.W2) + self.b2
        self.A2 = self.softmax(self.Z2)
        return self.A2

    def backward(self, X, y, learning_rate=0.01):
        """Retropropagación"""
        batch_size = X.shape[0]

        # Convertir y a one-hot
        y_one_hot = np.zeros((batch_size, 10))
        y_one_hot[np.arange(batch_size), y.astype(int)] = 1

        # Gradientes de la capa de salida
        dZ2 = self.A2 - y_one_hot
        dW2 = np.dot(self.A1.T, dZ2) / batch_size
        db2 = np.sum(dZ2, axis=0, keepdims=True) / batch_size
```

```

        # Gradientes de la capa oculta
        dZ1 = np.dot(dZ2, self.W2.T) * self.relu_derivative(self.Z1)
        dW1 = np.dot(X.T, dZ1) / batch_size
        db1 = np.sum(dZ1, axis=0, keepdims=True) / batch_size

        # Actualización de pesos y sesgos
        self.W2 -= learning_rate * dW2
        self.b2 -= learning_rate * db2
        self.W1 -= learning_rate * dW1
        self.b1 -= learning_rate * db1

    def predict(self, X):
        """Realizar predicciones"""
        return np.argmax(self.forward(X), axis=1)

    def calculate_accuracy(self, X, y):
        """Calcular precisión"""
        predictions = self.predict(X)
        return np.mean(predictions == y.astype(int))

```

```

[5]: # Convertir los datos a arrays de NumPy si están en formato pandas
X_train = X_train.to_numpy() if hasattr(X_train, 'to_numpy') else np.
    ↪array(X_train)
X_test = X_test.to_numpy() if hasattr(X_test, 'to_numpy') else np.array(X_test)
y_train = y_train.to_numpy() if hasattr(y_train, 'to_numpy') else np.
    ↪array(y_train)
y_test = y_test.to_numpy() if hasattr(y_test, 'to_numpy') else np.array(y_test)

# Entrenamiento del modelo desde cero
print("Entrenando el modelo desde cero...")
model = NeuralNetworkFromScratch(784, 128, 10)

# Parámetros de entrenamiento
epochs = 10
batch_size = 32
learning_rate = 0.1

# Entrenamiento
for epoch in range(epochs):
    # Mezclamos los datos
    indices = np.random.permutation(len(X_train))
    X_train_shuffled = X_train[indices]
    y_train_shuffled = y_train[indices]

    # Entrenamiento por lotes
    for i in range(0, len(X_train), batch_size):
        batch_X = X_train_shuffled[i:i+batch_size]

```

```

    batch_y = y_train_shuffled[i:i+batch_size]

    # Forward y backward pass
    model.forward(batch_X)
    model.backward(batch_X, batch_y, learning_rate)

    # Calculamos y mostramos la precisión
    train_acc = model.calculate_accuracy(X_train, y_train)
    test_acc = model.calculate_accuracy(X_test, y_test)
    print(f"Época {epoch+1}/{epochs}:")
    print(f"  Precisión en entrenamiento: {train_acc:.4f}")
    print(f"  Precisión en prueba: {test_acc:.4f}")

```

Entrenando el modelo desde cero...

Época 1/10:

Precisión en entrenamiento: 0.9474

Precisión en prueba: 0.9450

Época 2/10:

Precisión en entrenamiento: 0.9675

Precisión en prueba: 0.9595

Época 3/10:

Precisión en entrenamiento: 0.9758

Precisión en prueba: 0.9668

Época 4/10:

Precisión en entrenamiento: 0.9788

Precisión en prueba: 0.9694

Época 5/10:

Precisión en entrenamiento: 0.9845

Precisión en prueba: 0.9705

Época 6/10:

Precisión en entrenamiento: 0.9861

Precisión en prueba: 0.9713

Época 7/10:

Precisión en entrenamiento: 0.9902

Precisión en prueba: 0.9739

Época 8/10:

Precisión en entrenamiento: 0.9898

Precisión en prueba: 0.9737

Época 9/10:

Precisión en entrenamiento: 0.9923

Precisión en prueba: 0.9751

Época 10/10:

Precisión en entrenamiento: 0.9945

Precisión en prueba: 0.9765

1.4 3. Implementación con Scikit-learn

Ahora implementaremos el clasificador usando MLPClassifier de scikit-learn.

```
[7]: from sklearn.neural_network import MLPClassifier

# Crear y entrenar el modelo
print("Entrenando el modelo con scikit-learn...")
sklearn_model = MLPClassifier(
    hidden_layer_sizes=(128, 64), # Más capacidad en la red
    max_iter=100, # Más iteraciones
    learning_rate_init=0.01, # Tasa de aprendizaje más baja
    batch_size=32,
    random_state=42,
    verbose=True # Mostrar progreso
)

sklearn_model.fit(X_train, y_train)

# Evaluar el modelo
train_acc = sklearn_model.score(X_train, y_train)
test_acc = sklearn_model.score(X_test, y_test)

print("\nResultados del modelo scikit-learn:")
print(f"Precisión en entrenamiento: {train_acc:.4f}")
print(f"Precisión en prueba: {test_acc:.4f}")
```

Entrenando el modelo con scikit-learn...

```
Iteration 1, loss = 0.26802934
Iteration 2, loss = 0.17944961
Iteration 3, loss = 0.16807156
Iteration 4, loss = 0.15994570
Iteration 5, loss = 0.14762112
Iteration 6, loss = 0.14853949
Iteration 7, loss = 0.14262241
Iteration 8, loss = 0.14564313
Iteration 9, loss = 0.14355451
Iteration 10, loss = 0.13898402
Iteration 11, loss = 0.14377682
Iteration 12, loss = 0.13994149
Iteration 13, loss = 0.13774052
Iteration 14, loss = 0.14414539
Iteration 15, loss = 0.13889149
Iteration 16, loss = 0.13340322
Iteration 17, loss = 0.14064711
Iteration 18, loss = 0.13436761
Iteration 19, loss = 0.13329662
Iteration 20, loss = 0.13507374
Iteration 21, loss = 0.14444904
Iteration 22, loss = 0.14031348
Iteration 23, loss = 0.13637035
```

```

Iteration 24, loss = 0.14000033
Iteration 25, loss = 0.13127813
Iteration 26, loss = 0.14695849
Iteration 27, loss = 0.13516453
Iteration 28, loss = 0.13075623
Iteration 29, loss = 0.14330079
Iteration 30, loss = 0.14147081
Iteration 31, loss = 0.13216239
Iteration 32, loss = 0.13218042
Iteration 33, loss = 0.14053664
Iteration 34, loss = 0.13759676
Iteration 35, loss = 0.14157339
Iteration 36, loss = 0.13992523
Iteration 37, loss = 0.12933392
Iteration 38, loss = 0.13834292
Iteration 39, loss = 0.13683980
Iteration 40, loss = 0.14093031
Iteration 41, loss = 0.13429041
Iteration 42, loss = 0.13416527
Iteration 43, loss = 0.13987663
Iteration 44, loss = 0.13934151
Iteration 45, loss = 0.13929839
Iteration 46, loss = 0.13881829
Iteration 47, loss = 0.14007633
Iteration 48, loss = 0.13473418
Training loss did not improve more than tol=0.000100 for 10 consecutive epochs.
Stopping.

```

Resultados del modelo scikit-learn:
Precisión en entrenamiento: 0.9834
Precisión en prueba: 0.9661

1.5 4. Comparación Visual de Resultados

Visualizaremos algunas predicciones de ambos modelos para comparar su rendimiento.

```

[8]: # Seleccionamos algunas imágenes aleatorias para visualizar
n_samples = 10
random_indices = np.random.randint(0, len(X_test), n_samples)

# Obtenemos predicciones de ambos modelos
scratch_predictions = model.predict(X_test[random_indices])
sklearn_predictions = sklearn_model.predict(X_test[random_indices])
true_labels = y_test[random_indices]

# Visualizamos los resultados
fig, axes = plt.subplots(2, 5, figsize=(15, 6))
for idx, ax in enumerate(axes.flat):

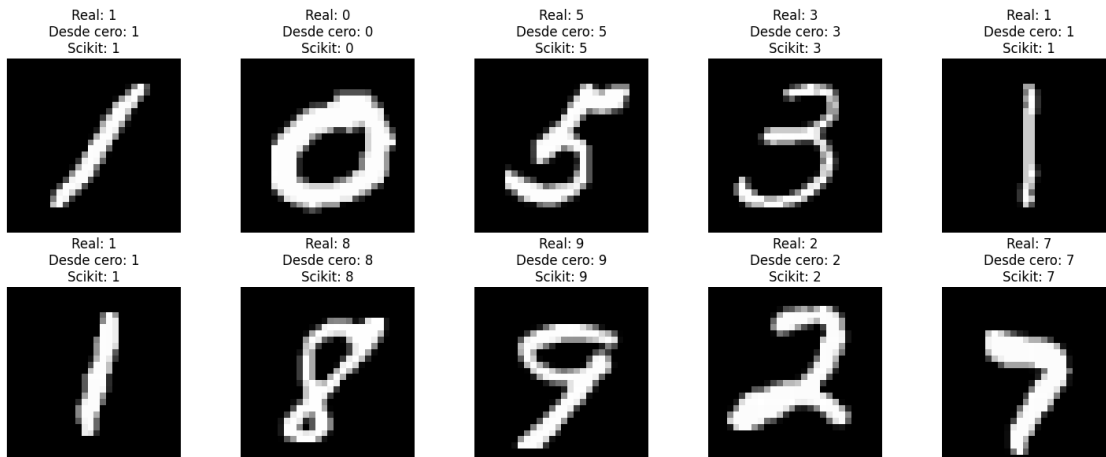
```

```

ax.imshow(X_test[random_indices[idx]].reshape(28, 28), cmap='gray')
ax.axis('off')
ax.set_title(f'Real: {true_labels[idx]}\nDesde cero: {
↳scratch_predictions[idx]}\nScikit: {sklearn_predictions[idx]}')

plt.tight_layout()
plt.show()

```



1.5.1 Conclusiones

1. Implementación desde cero:

- Se desarrolló una red neuronal utilizando únicamente NumPy, implementando manualmente las funciones de activación, propagación hacia adelante y retropropagación.
- El modelo alcanzó una precisión en el conjunto de prueba de **97.65%**, lo que demuestra que una implementación manual bien diseñada puede ser efectiva para resolver problemas de clasificación como MNIST.
- Este enfoque permite un control total sobre cada paso del proceso, lo que es ideal para comprender los fundamentos del aprendizaje automático.

2. Implementación con Scikit-learn:

- Se utilizó el modelo `MLPClassifier` de Scikit-learn con una arquitectura similar a la red neuronal implementada desde cero.
- El modelo alcanzó una precisión en el conjunto de prueba de **96.61%**, ligeramente inferior al modelo manual.
- Este enfoque es más rápido y fácil de implementar, pero ofrece menos control sobre los detalles internos del modelo.

3. Comparación de resultados:

- Ambos modelos mostraron un rendimiento similar, con una ligera ventaja para el modelo implementado desde cero en términos de precisión.
- La visualización de predicciones muestra que ambos modelos son consistentes y precisos en las muestras seleccionadas.

1.5.2 Recomendaciones

1. Para futuros proyectos:

- Utilizar la implementación desde cero para aprender y comprender los fundamentos de las redes neuronales.
- Optar por bibliotecas como Scikit-learn o TensorFlow para proyectos más grandes o cuando el tiempo de desarrollo sea limitado.

2. Optimización del modelo:

- Experimentar con diferentes arquitecturas (más capas ocultas o neuronas) y parámetros (tasa de aprendizaje, tamaño de lotes) para mejorar el rendimiento.
- Considerar el uso de técnicas de regularización como dropout para evitar el sobreajuste.

3. Uso de recursos:

- Si se trabaja en la nube, aprovechar entornos con GPU para acelerar el entrenamiento.
- Reducir el tamaño del dataset o el número de épocas durante las pruebas para minimizar el consumo de recursos.

4. Documentación y análisis:

- Continuar documentando cada paso del proceso en celdas Markdown para facilitar la comprensión y reproducibilidad del proyecto.
- Realizar análisis adicionales, como la matriz de confusión, para identificar patrones en los errores de clasificación.